

# SimAM

## 论文研究内容

论文原文：

“Specifically, we base on some well-known neuroscience theories and propose to optimize an energy function to find the importance of each neuron. We further derive a fast closed-form solution for the energy function, and show that the solution can be implemented in less than ten lines of code.”

总结：

作者基于一些著名的神经科学理论，提出了一个能量函数用来计算feature map中每个神经元的重要性。

## 原理

论文依据的神经科学理论：

“在视觉神经科学中，信息量最大的神经元通常与周围神经元的发射模式截然不同。此外，活跃的神经元还可能抑制周围神经元的活动，这种现象被称为空间抑制。换句话说，在视觉处理过程中，具有明显空间抑制效应的神经元应该被赋予更高的优先级（即重要性）。 ”


根据以上理论，论文提出了一种方法：测量feature map中的一个目标神经元与其他神经元之间的线性分离度。公式如下：

$$e_t(w_t, b_t, y, x_i) = (y_t - \hat{t})^2 + \frac{1}{M-1} \sum_{i=1}^{M-1} (y_o - \hat{x}_i)^2. \quad (1)$$

Here,  $\hat{t} = w_t t + b_t$  and  $\hat{x}_i = w_t x_i + b_t$  are linear transforms of  $t$  and  $x_i$ , where  $t$  and  $x_i$  are the target neuron and other neurons in a single channel of the input feature  $\mathbf{X} \in \mathbb{R}^{C \times H \times W}$ .  $i$  is index over spatial dimension and

个人理解：

$y_t$ 与 $y_o$ 是两个对立点，表示目标神经元在 $y_t$ 点的离散程度，表示其他神经元在 $y_o$ 点的离散程度，用图理解如下：



如此， $e_t$ 越小，则表示目标神经元离 $y_t$ 点越近，其他神经元离 $y_o$ 点越近，最终的结果就是：目标神经元和其他神经元线性分离出来了。

在论文中，为了方便计算，取 $y_t=1$ ， $y_o=-1$ ，再添加上正则项，最后得到能量函数为：

$$e_t(w_t, b_t, \mathbf{y}, x_i) = \frac{1}{M-1} \sum_{i=1}^{M-1} (-1 - (w_t x_i + b_t))^2 + (1 - (w_t t + b_t))^2 + \lambda w_t^2. \quad (2)$$

要使 $e_t$ 最小，意味着要求导数找极值，但是要对feature map的每一个神经元进行这个过程，计算量是非常大的。由此，论文提出了一个近似解（不大理解怎么推导出来的），如下：

$$w_t = -\frac{2(t - \mu_t)}{(t - \mu_t)^2 + 2\sigma_t^2 + 2\lambda}, \quad (3)$$

$$b_t = -\frac{1}{2}(t + \mu_t)w_t. \quad (4)$$

$\mu_t = \frac{1}{M-1} \sum_{i=1}^{M-1} x_i$  and  $\sigma_t^2 = \frac{1}{M-1} \sum_{i=1}^{M-1} (x_i - \mu_t)^2$  are mean and variance calculated over all neurons except  $t$  in that channel. Since existing solutions shown in Eqn (3) and

因此，能量函数的表达式变为：

$$e_t^* = \frac{4(\hat{\sigma}^2 + \lambda)}{(t - \hat{\mu})^2 + 2\hat{\sigma}^2 + 2\lambda}, \quad (5)$$

where  $\hat{\mu} = \frac{1}{M} \sum_{i=1}^M x_i$  and  $\hat{\sigma}^2 = \frac{1}{M} \sum_{i=1}^M (x_i - \hat{\mu})^2$ . Eqn (5) indicates that the lower energy  $e_t^*$ , the neuron  $t$  is more distinctive from surround neurons, and more important for visual processing. Therefore, the importance of each neuron can be obtained by  $1/e_t^*$ . Akin to our method, (Aubry

最后，论文使用 $1/e_t$ 作为权重系数，并添加了一个sigmoid函数增加非线性。

$$\tilde{\mathbf{X}} = \textit{sigmoid}(\frac{1}{\mathbf{E}}) \odot \mathbf{X}, \quad (6)$$

where  $\mathbf{E}$  groups all  $e_t^*$  across channel and spatial dimensions. *sigmoid* is added to restrict too large value in  $\mathbf{E}$ . It will not influence the relative importance of each neuron because *sigmoid* is a monofonic function.

**pytorch代码**

```
class SimAM(nn.Module):
    def __init__(self, c1, c2):
        super(SimAM, self).__init__()
        self.lamdba = 0.0001
        self.sigmoid = nn.Sigmoid()

    def forward(self, X):
        # spatial size
        n = X.shape[2] * X.shape[3] - 1
```

"""  
要添加keepdim=True,  
不添加的话, 结果的维度会变成2维的, 和原来的4维不  
对应

```
例如: 原来b*c*h*w ---> b*c
"""
# square of (t - u)
x_mean = X.mean(dim=[2, 3], keepdim=True)
d = (X - x_mean)
d = d.pow(2)
```

"""  
要添加keepdim=True,  
不添加的话, 结果的维度会变成2维的, 和原来的4维不  
对应

```
例如: 原来b*c*h*w ---> b*c
"""
# d.sum() / n is channel variance
v = d.sum(dim=[2, 3], keepdim=True)
v = v / n

# E_inv groups all importance of X
E_inv = d / (4 * (v + self.lamdba)) + 0.5
```

```
# return attended features  
return X * self.sigmoid(E_inv)
```